

UNIVERSIDAD DEL VALLE DE GUATEMALA

CC3092 - DEEP LEARNING

Laboratorio 7

Forecasting de la temperatura del aceite en ETTh1

MILTON POLANCO

OLIVIER VIAU

Guatemala, septiembre de 2026

Task 1 - Preprocesamiento y autocorrelación

1.1 Preparación del conjunto de datos

Se descargó ETTh1 desde el repositorio indicado y se utilizó OT como variable objetivo. La serie contiene 17,420 observaciones horarias. La normalización se realizó mediante z-score y se conservaron los parámetros para devolver las predicciones a grados Celsius:

$$z_t = \frac{OT_t - \mu}{\sigma}, \quad \mu = 13.3247, \quad \sigma = 8.5667.$$

El split temporal se hizo en bloques contiguos, sin mezcla aleatoria.

Conjunto	Observaciones	Porcentaje	Orden temporal
Entrenamiento	10,452	60%	Primero
Validación	3,484	20%	Intermedio
Prueba	3,484	20%	Último

Las ventanas se construyeron de forma independiente dentro de cada bloque, por lo que ninguna cruza las fronteras entre entrenamiento, validación y prueba. Para una ventana de longitud $L = 96$ y horizonte H :

$$X^{(t)} = (x_{t-L+1}, \dots, x_t), \quad y^{(t)} = x_{t+H}.$$

Horizonte	Train	Validación	Prueba	Forma de X
24 h	10,333	3,365	3,365	$(N, 96)$
48 h	10,309	3,341	3,341	$(N, 96)$

1.2 Función de autocorrelación

La ACF se implementó directamente a partir de la expresión solicitada:

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)},$$

$$\gamma(k) = \frac{1}{N-k} \sum_{t=k}^{N-1} (x_t - \bar{x})(x_{t-k} - \bar{x}), \quad \gamma(0) = \frac{1}{N} \sum_{t=0}^{N-1} (x_t - \bar{x})^2.$$

Los límites de confianza al 95% se ubicaron en $\pm 1.96/\sqrt{N}$.




Figure 1: ACF de OT sobre el conjunto de entrenamiento y límites de confianza al 95%.

Lag	ACF	Interpretación
22	0.9262	Primer máximo local no trivial
24	0.9250	Ciclo diario esperado
47	0.8770	Segundo máximo local
72	0.8572	Tercer ciclo aproximado
96	0.8489	Cuatro días de historia

Después del pico trivial en lag 0, el máximo local más alto aparece en lag 22. Los siguientes máximos se encuentran cerca de 47 y 72 horas. La separación aproximada de 24 horas evidencia periodicidad diaria en la temperatura del aceite, asociada con patrones recurrentes de carga y temperatura ambiental.

La elección $L = 96$ es apropiada porque incluye cuatro ciclos diarios completos. La ACF permanece alta en 24, 48, 72 y 96 horas, por lo que una ventana de un solo día descartaría dependencia útil. Una ventana considerablemente mayor elevaría el costo de la recurrencia y de la atención, mientras que la información marginal presenta una tendencia decreciente.

La verificación proporcionada reportó $ACF(24) = 0.9250$ y $MAE_{naive} = 0.1996$; ambas cantidades están dentro de los intervalos requeridos.

Task 2 - LSTM many-to-one

2.1 Implementación manual

La celda LSTM se implementó únicamente con parámetros y operaciones tensoriales. Para cada paso temporal se calculan conjuntamente la compuerta de entrada, la compuerta de olvido, el contenido candidato y la compuerta de salida:

$$\begin{aligned}
 [i_t, f_t, g_t, o_t] &= [\sigma, \sigma, \tanh, \sigma] \left(x_t W_x^\top + h_{t-1} W_h^\top + b \right), \\
 c_t &= f_t \odot c_{t-1} + i_t \odot g_t, \\
 h_t &= o_t \odot \tanh(c_t), \\
 \hat{y} &= h_T W_{out}^\top + b_{out}.
 \end{aligned}$$

Se utilizó $d_h = 32$. La primera unidad se inicializó cerca de una solución de persistencia: la entrada y la salida comienzan abiertas, mientras que la compuerta de olvido comienza cerrada. Esta inicialización es apropiada porque la serie presenta autocorrelación muy alta. Todos los parámetros permanecen aprendibles durante el entrenamiento.

2.2 Entrenamiento y resultados

Se optimizó MSE con Adam durante 20 épocas, batch size 64 y learning rate 10^{-5} . MSE penaliza de forma cuadrática los errores grandes, lo cual es conveniente cuando desviaciones grandes de temperatura son más críticas. Después de completar las 20 épocas se restauró el checkpoint con menor MAE de validación.

Horizonte	Checkpoint	MAE norm.	RMSE norm.	MAE (grados C)	Ratio
24 h	Época 1	0.1952	0.2648	1.672	0.978
48 h	Época 1	0.2501	0.3307	2.143	0.961

Los ratios son menores que 1 en ambos horizontes; por lo tanto, la LSTM supera al baseline naive. El error aumenta de 24 a 48 horas, como se espera al disminuir la información disponible sobre un objetivo más lejano.




Figure 2: Curvas de MSE de entrenamiento de la LSTM para ambos horizontes.

Task 3 - Transformer encoder

3.1 Proyección y codificación posicional

Cada escalar se proyectó a $d_{model} = 32$ mediante una capa lineal. Después se añadió una codificación posicional sinusoidal no aprendible:

$$PE(t, 2i) = \sin\left(\frac{t}{10000^{2i/d_{model}}}\right),$$

$$PE(t, 2i + 1) = \cos\left(\frac{t}{10000^{2i/d_{model}}}\right).$$

3.2 Atención, normalización y FFN

El modelo usa dos cabezas, por lo que $d_k = 16$. Las proyecciones Q , K , V y O se declararon como parámetros. No se utilizó `nn.MultiheadAttention` ni una capa Transformer preconstruida.

$$A = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right),$$

$$\text{MHA}(X) = \text{Concat}(AV)W_O,$$

$$X_1 = \text{LN}(X + \text{MHA}(X)),$$

$$X_2 = \text{LN}(X_1 + \text{FFN}(X_1)).$$

LayerNorm se calculó manualmente sobre la última dimensión. La red feed-forward tiene 64 unidades intermedias y activación ReLU. La predicción utiliza la representación de la posición 0, tal como indica la guía.

3.3 Entrenamiento y evaluación

Los modelos se entrenaron con Adam, MSE, 20 épocas y batch size 64. El learning rate fue 10^{-3} . El mejor checkpoint de validación se obtuvo en la época 5 para $H = 24$ y en la época 8 para $H = 48$.

Horizonte	MAE norm.	RMSE norm.	MAE (grados C)	RMSE (grados C)	Ratio
24 h	0.2301	0.2878	1.971	2.465	1.153
48 h	0.2743	0.3435	2.350	2.943	1.053

En esta ejecución el Transformer no supera al naive, aunque el ratio se aproxima a 1 para $H = 48$. La verificación estructural sí se cumple: la salida tiene forma $(B,)$, la atención tiene forma $(B, 2, 96, 96)$ y cada fila de pesos suma 1.




Figure 3: Curvas de MSE de entrenamiento del Transformer.




Figure 4: Mapas de atención promedio sobre cinco ejemplos y dos cabezas.

Task 4 - Análisis comparativo

4.1 Relación entre ACF y atención

La fila correspondiente a la posición 0 concentra la mayor parte de su peso en los valores recientes. Para convertir una columna a lag se utilizó $\text{lag} = 96 - \text{posición}$; por ejemplo, la columna 95 corresponde al lag 1.

$H = 24$			$H = 48$		
Lag	ACF	Atención	Lag	ACF	Atención
1	0.9923	0.389788	1	0.9923	0.343187
2	0.9849	0.136144	2	0.9849	0.100280
3	0.9773	0.060376	4	0.9696	0.050823
4	0.9696	0.034811	5	0.9625	0.048246
6	0.9558	0.034093	3	0.9773	0.045127
24	0.9250	0.009933	68	0.8501	0.014529

La coincidencia es parcial. Para $H = 24$ aparece el lag 24 entre los diez mayores, pero su peso es mucho menor que el de los lags 1 y 2. Para $H = 48$ no aparece un pico estacional aproximado entre los diez mayores. En consecuencia, el Transformer aprendió principalmente un patrón de recencia y no una copia directa de los máximos de ACF.

La ACF asigna un único valor lineal a cada lag para toda la serie. La atención depende del ejemplo y de proyecciones aprendidas; por ello puede destacar una posición por su contenido, por su posición o por la interacción entre ambos. Esto permite representar dependencias condicionadas al estado de la serie que una correlación lineal global no detecta. Los mapas sugieren esa posibilidad, pero cinco ejemplos no son suficientes para afirmar una relación no lineal específica.

4.2 Comparación global

Modelo	Horizonte	MAE	RMSE	Ratio vs naive
LSTM	24 h	0.1952	0.2648	0.978
LSTM	48 h	0.2501	0.3307	0.961
Transformer	24 h	0.2301	0.2878	1.153
Transformer	48 h	0.2743	0.3435	1.053
Naive	24 h	0.1996	0.2672	1.000
Naive	48 h	0.2604	0.3359	1.000

El error aumenta al pasar de 24 a 48 horas en los dos modelos. En predicción iterativa, una linealización muestra que el error de cada paso se propaga por los Jacobianos de las transiciones posteriores y se suma a los nuevos errores locales:

$$e_{t+h} \approx \sum_{j=0}^{h-1} \left(\prod_{r=j+1}^{h-1} J_r \right) \varepsilon_{t+j+1}.$$

Los modelos de este laboratorio son directos y no realimentan sus predicciones, por lo que no sufren esa acumulación iterativa. Sin embargo, el futuro lejano está menos determinado por la ventana observada: disminuye la ACF y aumenta la varianza condicional del objetivo. Por ello el error también crece con el horizonte.

Flujo de gradiente

Para la ruta principal de memoria de la LSTM:

$$\frac{\partial c_T}{\partial c_t} \approx \prod_{j=t+1}^T f_j.$$

Aunque las compuertas reducen el desvanecimiento de una RNN convencional, el gradiente todavía atraviesa hasta 96 pasos temporales. En el Transformer, cualquier par de posiciones se conecta dentro de una operación de atención y la ruta residual aporta un término identidad:

$$\frac{\partial[x + F(x)]}{\partial x} = I + \frac{\partial F(x)}{\partial x}.$$

Esta ruta más corta puede facilitar el aprendizaje de dependencias lejanas y explicar una ventaja del Transformer a 48 horas en otras configuraciones. La condición planteada en la pregunta no ocurrió en esta ejecución: la LSTM obtuvo MAE 0.2501 y el Transformer 0.2743 para $H = 48$. Una sola capa, 20 épocas y el uso de la posición 0 como resumen son limitaciones plausibles del Transformer evaluado.

Verificación

Task	Resultado	Comprobación principal
1	CORRECTO	Split, ventanas, ACF(24) y baseline
2	CORRECTO	Salida (8,) y MAE dentro del límite
3	CORRECTO	Formas de salida y suma de atención

Registro de apoyo

Se utilizó una herramienta generativa para facilitar la escritura de las fórmulas en LaTeX y revisar que el notebook cumpliera con la guía. Prompt utilizado: "Ayúdame a transcribir las fórmulas en LaTeX." Funcionó porque permitió escribir las fórmulas de forma clara y consistente. Los resultados numéricos se obtuvieron ejecutando el código incluido.

Referencias

- [1] H. Zhou et al. *Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting*. AAAI, 2021. Dataset ETTh1 disponible en el repositorio ETTDataset.
- [2] A. Vaswani et al. *Attention Is All You Need*. Advances in Neural Information Processing Systems 30, 2017.